

Predikcija saobraćajnih gužvi na osnovu video materijala nadzornih kamera

Mihaela Osmajić
Fakultet tehničkih nauka
Univerzitet u Novom Sadu
Trg Dositeja Obradovića 6
21000 Novi Sad
mihaela.osmajic@uns.ac.rs

Marija Golubović
Fakultet tehničkih nauka
Univerzitet u Novom Sadu
Trg Dositeja Obradovića 6
21000 Novi Sad
marija.golubovic@uns.ac.rs

Apstrakt— Saobraćajne gužve predstavljaju sve veći izazov za saobraćajne infrastrukture širom sveta, uzrokujući ekonomske gubitke, povećanu stopu saobraćajnih nesreća i ozbiljne ekološke probleme. U ovom istraživanju razvijen je pristup za predikciju saobraćajnih gužvi na osnovu video materijala nadzornih kamera. Obradili smo video materijale sa kamere postavljene na ulici Terazije u Beogradu korišćenjem modela YOLO (*You Only Look Once*) za detekciju vozila i DeepSort (*Simple Online and Realtime Tracking*) algoritma za praćenje njihovog kretanja, i dopunili ih meteorološkim podacima, kreirajući skup podataka nad kojim je obučeno više modela mašinskog učenja. Među testiranim modelima, XGBoost (*Extreme Gradient Boosting*) se istakao kao najefikasniji, postigavši impresivnu $f1$ meru od 96%. Ova studija doprinosi razumevanju problema saobraćajnih gužvi i pruža osnovu za razvoj sistema koji bi mogao unaprediti efikasnost upravljanja saobraćajnom mrežom i smanjiti negativne posledice gužvi na ekonomiju, bezbednost i životnu sredinu.

Ključne reči—saobraćajna gužva, XGBoost, video nadzor, YOLO, DeepSort

I. UVOD

Saobraćajne gužve predstavljaju opterećenje saobraćajnih infrastrukture usled kojih dolazi do usporavanja ili prekida u protoku saobraćaja. Njihova učestalost je značajno porasla od druge polovine 20. veka, a svake godine se dodatno povećava usled porasta broja vozila na putevima [11]. Prema istraživanjima, saobraćajne gužve stvaraju ogromne gubitke u ekonomiji svake zemlje [1]. Nisu samo ekonomski aspekti oni koji su ugroženi; saobraćajne gužve doprinose i povećanju saobraćajnih nesreća. Što je više vozila na putu, veća je verovatnoća za sudare i ozbiljne povrede. Pored toga, imaju ozbiljan ekološki pečat. Transportni sektor se ističe kao jedan od glavnih krivaca za emisije gasova, posebno ugljen-dioksida. Prema izveštaju [3], transportni sektor je identifikovan kao ključni izvor emisija štetnih gasova. Ovi problemi nisu samo teorijski; oni imaju konkretne posledice po zdravlje ljudi. Zagađenje vazduha izazvano saobraćajnim gužvama stvara ozbiljne zdravstvene probleme. Prema dokumentima Svetske zdravstvene organizacije (SZO) [2], zagađenje vazduha povezano sa saobraćajem predstavlja jedan od glavnih faktora rizika za ljudsko zdravlje. Uzmimo primer Srbije. Prema izveštaju [4] IQ Air-a, u periodu od 2018. do 2022. godine,

Srbija se našla na 33. mestu najzagađenijih država sveta. Ovo jasno pokazuje da saobraćajne gužve predstavljaju veliki globalni problem.

Razvijanje sistema koji bi nagoveštavao gužvu, indirektno bi sugerisao učesnicima u saobraćaju promenu putanje i smanjio vreme putovanja, a samim tim i redukovao saobraćajne nezgode i količine izduvnih gasova. Takođe, nadležne institucije koje se bave izgradnjom saobraćajnih puteva, bi imale uvid u uska grla saobraćaja i mogli bi efikasnije da planiraju saobraćajnu mrežu.

U ovom radu želimo da predstavimo naše rešenje za problem predikcije saobraćajnih gužvi koristeći video materijale nadzornih kamera. Naše istraživanje bazira se na analizi video snimaka sa kamere postavljene na lokaciji Terazije u Beogradu, uz dopunu meteorološkim podacima dobijenim sa određenog sajta. Na osnovu ovih podataka formiran je detaljan skup podataka, koji je zatim korišćen za obuku raznih prediktivnih modela. Među testiranim modelima, XGBoost se istakao kao najefikasniji, sa impresivnom $f1$ merom od 96%.

Izdvojile bismo jedinstvenost našeg pristupa u načinu ekstrakcije, veoma bitnih obeležja, poput broja vozila i srednje relativne brzine, kao nešto po čemu se naše rešenje razlikuje od drugih, iako se izbor relevantnih obeležja, metodologija i mere performanse oslanjaju na prethodna istraživanja

U nastavku će detaljnije biti objašnjeni različiti aspekti problema i samog rešenja. U poglavlju 2 je napravljen kratak pregled radova koji se bave sličnim problemom. Za svaki rad je naveden zaključak zašto je on u našem istraživanju bio bitan. Poglavlje 3 opisuje skup podataka: njegova obeležja, dimenzije i podelu na podskupove koji su korišćeni u različitim svrhama, poput treniranja, validacije i testiranja. Metodologijom rada se bavi poglavlje 4, naveden je proces kreiranja skupa podataka, način njegove obrade, kao i obučavanje modela u svrhu predikcije i optimizacija njihovih parametara. U poglavlju 5 prikazani su rezultati, pri čemu su identifikovani problemi, ograničenja ali i potencijalna rešenja. Na kraju se nalazi zaključak koji sumira ovo istraživanje.

II. PRETHODNA REŠENJA

Pristupi rešavanja problema predikcije saobraćajnih gužvi ovog rada se oslanjaju na prethodna istraživanja navedena u nastavku teksta.

Istraživanje [5] se fokusira na razvoj desktop aplikacije za predviđanje saobraćajnih gužvi u Islamabadu, Pakistanu. Podaci su prikupljeni sa *Google Map* aplikativnog interfejsa, uz dodatak informacija o meteorološkim uslovima i praznicima. Klasifikacija prometnog stanja obuhvata pet nivoa, a analizirani su modeli poput Random Forest, Logističke regresije, Naive Bayes, XGBoost, GradientBoost i KNN (*K-Nearest Neighbors*). Kako su KNN i algoritmi zasnovani na stablima odlučivanja pokazali najbolje rezultate, iskoristili smo ih u rešenju. Takođe, meteorološke uslove, dane u nedelji i vremenski interval smo koristili kao obeležja po uzoru na ovo rešenje.

Rad [6] se bavi upotrebom različitih ansambl metoda u predviđanju saobraćajnih gužvi u različitim gradovima, uključujući Bengaluru, Manila, Bogotu, Mumbai i Punu. Autori su primenili kombinaciju AdaBoost-a sa stablima odlučivanja, ARIMA(*Autoregressive Integrated Moving Average*) i XGBOOST modele. Analizirane su performanse modela koristeći metrike poput *f1* mere, osetljivosti i preciznosti, a istaknuto je da je Stacking model pružio izuzetne rezultate. Takođe, uočile smo da je, suprotno prethodnom istraživanju, SVM (*Support Vector Machines*) dao dobre rezultate. Iz tog razloga, Stacking, SVM i pomenute mere performanse su korišćene i u našem rešenju.

Istraživanje [7] se fokusira na upotrebu LSTM (*Long Short-Term Memory*) modela u predviđanju saobraćajnih gužvi u provinciji Gangnam-gu, Seul. Podaci su sakupljeni sa 1630 povezanih cesta tokom 30 dana, uz analizu faktora kao što su brzina automobila i nedostajuće vrednosti u podacima. Kao mera performanse, korišćena je MAPE (*Mean Absolute Percentage Error*), a rezultati su pokazali da LSTM model ima značajno bolje performanse od drugih modela čak i u slučaju nedostajućih vrednosti u podacima. Na osnovu rezultata ovog rada, uključili smo LSTM model u izbor modela za predikciju.

III. OPIS SKUPA PODATAKA

U nastavku će biti opisani skupovi podataka za detekciju vozila i za predikciju gužvi na osnovu video materijala.

A. Skup podataka za predikciju gužvi

Rešenje koristi samostalno kreiran skup podataka. Skup podataka je kreiran spajanjem, takođe samostalno kreiranih skupova podataka o vozilima i meteorološkim uslovima. Tačnije, svaka instanca konačnog skupa podataka poseduje podatke o vozilima i meteorološkim uslovima za interval od jednog sata, dok ciljna labela označava prisustvo gužve u tom intervalu. Podaci o meteorološkim uslovima za kreiranje skupa podataka o istim preuzeti su sa sajta wunderground.com [8] i oslikavaju stanje na putu informacijama o temperaturi, pritisku, vetru, vlažnosti, padavinama za svakih pola sata u toku dana. Skup podataka o vozilima je dobijen obradom video materijala kamere u realnom vremenu, postavljene u ulici Terzije u

Beogradu. Video materijali su preuzeti sa YouTube kanala Beograd Com [9].

Kamera promeni oko dvadesetak kadrova, pri čemu su izbačeni nerelevantni, poput prikaza isključivo pešaka. Promene kadrova nisu uniformne po minutaži i samim tim nemaju uniformnu raspodelu ni na nivou od 24h. Zbog nerelevantnih kadrova, njihovog izbacivanja i nejednakih dužina trajanja, morale smo da koristimo interval od sat vremena kao jedinicu posmatranja za procenu gužve.

Skupovi podataka su spojene na osnovu datuma i vremenskog intervala. Nakon svih obrada podataka konačna obeležja su:

- Datum
- Dan u nedelji
- Mesec
- Godina
- Vremenski interval
- Temperatura
- Vremenski uslovi
- Vlažnost
- Pravac vetra
- Brzina vetra
- Pritisak
- Stopa padavina
- Ukupan broj vozila
- Relativna srednja brzina

Inicijalni skup, nakon spajanja, je obuhvatao oko 1500 instanci, ali smo nakon eksplorativne analize uvidele da jednak broj instanci u vremenskim intervalima noći i dana dovodi do kreiranja klastera ciljne labele u odnosu na baš te intervale, što bi za posledicu imalo preprilagođavanje modela. Iz tog razloga smo redukovale skup podataka na 936 instanci izbacivši određen broj instanci vremenskog intervala noći, nebalansiranost pomenutog obeležja rezultovala je izbegavanju preprilagođenosti modela.

Kreiranje skupa podataka je bio najveći izazov u istraživanju iz prostog razloga što za takav zadatak treba vremena. Obrađivanje samo jednog dana rezultuje sa svega 24 instance, a zahteva značajne resurse i vreme. Zbog toga smo se odlučile da podatke podelimo na testni podskup, validacioni podskup i podskup za obučavanje modela u razmeri 10:20:70.

B. Skup podataka za detekciju vozila

Skup podataka za obučavanje modela detekcije vozila je samostalno kreiran anotiranjem fotografija dobijenih iz preuzetih video materijala. Sačinjen je od 1055 fotografija na kojima su anotirana 3 entiteta: automobili, autobusi i kamioni. Podaci su podaljeni u razmeri 10:20:70 na test, validacioni i podskup za obučavanje mreže.

IV. METODOLOGIJA

Metodologija ovog rešenja se može podeliti na šest celina: Kreiranje skupa podataka za detekciju vozila, obučavanje modela za detekciju, kreiranje skupa podataka o meteorološkim uslovima, kreiranje skupa podataka o vozila, integracija i obrada podataka i obučavanje modela za predikciju gužvi u saobraćaju.

A. Kreiranje skupa podataka za detekciju vozila

Anotacija 440 fotografija je izvršena pomoću Roboflow platforme [12]. Nad inicijalnim skupo podataka je izvršena augmentacija, radi izbegavanja prilagođenosti modela. Primenjene metode augmentacije bile su:

1. rotacija fotografije za $\pm 15^\circ$
2. skaliranje na 640x640 dimenziju

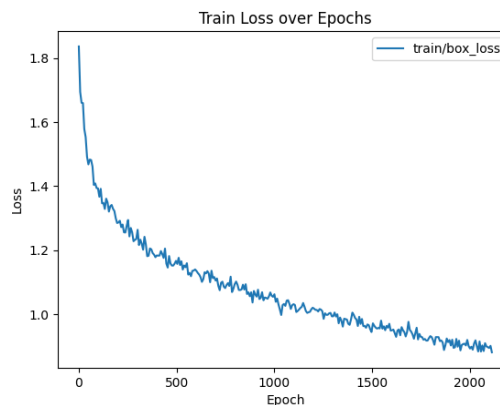
Fotografije su skalirane kako bi odgovarale ulazu neuronske mreže. Obrada fotografija je rezultovala skupom podataka od 1055 fotografija. Eksperimentisano je i sa drugim metodama augmentacije, poput izmene kontrasta i zasićenja boja, međutim, imali su negativan uticaj na performanse.

B. Obučavanje modela za detekciju vozila


Model za detekciju vozila je fino podešen (engl. fine-tuning) YOLO model verzije 8, preciznije model *yolov8n* sa 3.2M parametara i 225 slojeva (engl. layer). U literaturi slojevi su grupisani u tri dela: kičmu (engl. backbone), vrat (engl. neck) i glavu (engl. head). Fino podešavanje je izvršeno na delu YOLO arhitekture glave koji služi za detekciju, dok težine prethodnih delova nisu ažurirane pri tom doobučavanju. Model je obučen nad podskupom za obučavanje, optimalni hiperparametri su podešeni nad validacionim podskupom.

Uporedo sa obučavanjem YOLO modela obučavan je i SSD (*Single Shot multibox Detector*) [15] model, preciznije SSD300_VGG16_Weights model iz *PyTorch* [16] biblioteke. Model sa 26.3 miliona parametara i 70 slojeva je obučavan na COCO (*Common Objects in Context*) [17] skupu podataka sa ulazom veličine 300 x 300. Arhitektura obučenog modela je zasnovana na arhitekturi modela opisanoj u literaturi [15]. Model se sastoji od tri dijela: kičme, bazirane na VGG16 [18] modelu, dodatnih slojeva (eng. *extra layers*) i predikcionih slojeva (eng. *prediction layers*). Fino podešavanje modela je urađeno nad predikcionim slojevima koji služe za detekciju modela, dok slojevi zasnovani na VGG16 arhitekturi nisu mijenjani.

Obučavanje YOLO modela je izvršeno u 2000 iteracija sa veličinom serije (engl. batch) od 32 fotografije. AdamW [13] je korišćen kao optimajzer, pri čemu je dao statistički malo bolje rezultate od Stochastic Gradient Descent (SGD) [14]. Na samom početku smo imali problem prilagođenosti, iskoristili smo tehniku nasumičnog deaktiviranja neurona (engl. dropout), međutim imala je negativan uticaj na performanse, pa je ovaj problem rešen augmentacijom fotografija i izborom optimajzera. Na Fotografiji 1. se nalazi prikaz funkcije gubitka klasifikacije u odnosu na epohe, dok se na Fotografiji 2. nalazi funkcija gubitka lokacije okvira u odnosu na epohe.




Fotografija 1. Prikaz funkcije gubitka klasifikacije u odnosu na epohe




Fotografija 2. Prikaz funkcije gubitka lokacije okvira u odnosu na epohe

SSD model je obučavan na 200 iteracija sa veličinom serije od 5 fotografija. Model je treniran na grafičkoj karici GeForce RTX 3090, a prilikom treninga broj niti (eng. *workers*) koje će pripremati serije podataka (eng. *batches*) je podešen na 4. Korišten je Adam kao optimajzer, dok je stopa obučavanja dinamički podešavana uz pomoć MultiStepLR raspoređivača (eng. *scheduler*) iz *PyTorch* biblioteke. Raspoređivač je podešen da stopu obučavanja smanji nakon 45 epoha sa vrijednošću parametra α od 0.1. Prilikom treninga uz pomoć Python biblioteke Albumentations urađena je augmentacija podataka u vidu horizontalnog flipovanja sa vjerovatnoćom od 0.5, dodano je zamućenje (eng. *blur*), zamućenje nastalo kretanjem (eng. *motion blur*) i median zamućenje, za sva tri tipa zamućenja granica je postavljena na 3, a vjerovatnoća na 0.1. Ovaj tip augmentacije je od posebnog značaja, jer se slične situacije javljaju i u realnim uslovima kada su loši vremenski uslovi ili prevozna sredstva prolaze većom brzinom. Na Fotografiji 3 je prikazana funkcija gubitka u odnosu na broj iteracija.



Fotografija 3. Prikaz funkcije gubitka u odnosu na iteracije

Na Fotografiji 4. je prikazana F1 mera nad validacionim podskupom u odnosu na koeficijent sigurnosti. Na osnovu ovog grafikona izabran je koeficijent sigurnosti 0.25, koji predstavlja prag na osnovu kog će vozila biti detektovana.



Fotografija 4. Prikaz F1 mere u odnosu na koeficijent sigurnosti detekcije

C. Kreiranje skupa podataka o meteorološkim uslovima

Za svaki potreban datum su preuzeti podaci o meteorološkim uslovima mereni na svakih pola sata. Srednjom vrednošću smo uprosečili vrednosti kako bismo dobili podatke za vremenske intervale od sat vremena. Numeričke vrednosti su normalizovane, dok je pretvaranje kategoričkih u binarne izvršeno tehnikom *one-hot encoding*-a. Nakon analize podataka, primetile smo da postoje nedostajuće vrednosti. Kako bismo rešile taj problem, koristile smo različite strategije u zavisnosti od vrste podataka. Za numeričke podatke, popunile smo nedostajuće vrednosti koristeći srednju vrednost susednih podataka. Što se tiče kategoričkih podataka, odlučile smo se da nedostajuće vrednosti popunimo vrednostima iz prethodnog vremenskog intervala. Ova odluka proizilazi iz zaključka eksplorativne analize koja je pokazala da se u većini slučajeva, vrednosti za obeležja kao što su vremenski uslovi i pravac vetra menjaju relativno retko, obično ne više od dva do tri puta u toku dana. Produkt je skup podataka o meteorološkim uslovima.

Kreiranje skupa podataka o vozilima

Skup podataka o vozilima je kreiran kroz proces koji je uključivao detekciju vozila, praćenje njihovog kretanja, procenu brzine i obradu dobijenih podataka. Pre svega, potrebno je sakupiti video materijal. Kako bismo lakše, brže i nezavisnije obrađivali video materijale, sekale smo ih na interval od sat vremena, što predstavlja jedinicu posmatranja u našem radu. Takođe, bilo je potrebno je odstraniti nerelevantne kadrove koji bi samo crpeli resurse i vreme. Ovo je učinjeno korišćenjem unapred kreiranih maski koje su prepoznavale takve kadrove.


Nakon toga, jedan po jedan video je poslat na ulaz u sistem za detekciju i praćenje vozila, uz procenu njihove brzine. Jedan video snimak od jednog sata, kreira jedan skup podataka na nivou frejmova koji nakon obrade rezultuje jednom instancom konačnog skupa o vozilima. Na jednom frejmu se može naći par desetina vozila, jedan minut sadrži 1800 frejmova, prostom računicom, shvatamo da video materijal od jednog sata zahteva ogromne količine resursa i vremena. Ovaj problem smo rešile ubrzavanjem video materijala, kako koristimo relativnu srednju brzinu i kako ubrzavamo svaki video materijal jednakom brzinom, ova tehnika optimizacije ne utiče na rezultat.

Za detekciju vozila korišćen je ranije opisan, fino podešen YOLO model, dok je za praćenje kretanja vozila korišćen DeepSort algoritam [10]. Podatak o brzini vozila za jedan frejm dobijen je korišćenjem jednačine 1:

$$v = t * u(p1,p2) / pm \quad (1)$$

- v - brzina vozila
- u - udaljenost između pozicija vozila na dve frejma, izračunata euklidskim rastojanjem
- pm - konstanta koja predstavlja broj piksela po metru, faktor konverzije piksela u metre
- t - konstanta koja predstavlja vreme potrebno za pređeni put od 1m

Obrada skupa podataka o vozilima na nivou frejma je podrazumevala pre svega ekstrakciju instanci koje predstavljaju automobile, autobuse i kamione, sve ostali identifikovani objekti i podaci o njima nam nisu relevantni. Relativna srednja brzina vozila je podrazumevala usrednjavanje brzina i normalizaciju najvećom brzinom među podacima. Takođe pored ukupnog broja vozila ekstrahovani su podaci o broju automobila, kamiona i autobusa koji su potom normalizovani. Analizom podataka smo uvidele da podatak je podatak o broju vozila za svaku grupu linearno zavistan od ukupnog broja vozila, što bi značilo da nam je jedino važna informacija o ukupnom broju vozila, ne i o grupi. Fotografija 5. prikazuje zavisnost broja automobila u odnosu na ukupan broj vozila.



Fotografija 5. Prikaz zavisnosti broja automobila od ukupnog broja vozila

D. Integracija i obrada podataka

Skup podataka o meteorološkim uslovima i skup podataka spojeni su u odnosu na datum i vremenski interval, nakon čega su kreirana tri nova obeležja na osnovu datuma: dan u nedelji, mesec i godina. Obeležja dan u nedelji, mesec i vremenski interval su konvertovana u *one-hot* vektore.

Određivanje vrednosti ciljne labela izvršeno je primenom k-means klasterovanja. Ciljna labela predstavlja prisustvo gužve binarnog je tipa, što znači da su nam bila potrebna 2 klastera. Čime je kreiran konačan skup podataka.

E. Obučavanje modela za predikciju gužvi u saobraćaju

Za predikciju gužvi u saobraćaju odabrano je nekoliko modela mašinskog učenja i njihov ansambl:

- SVM
- KNN
- RandomForest
- XGBoost
- Stacking(SVM, KNN, RF,XGBoost)
- LSTM

Svi modeli su obučavani na podskupu za obučavanje, dok je optimizacija parametara izvršena nad validacionim podskupom pomoću *GridSerach*-a. Mere korišćene za evaluaciju su preciznost, osetljivost i f1 mera.

Optimalna metrika za KNN je minkovski, dok je optimalan broj suseda 9. Model XGBoost je optimizovan prema broju estimatora, maksimalnoj dubini i stopi učenja (engl. *learning-rate*). Optimalna dubina je 6, broj estimatora 300 a stopa učenja 0.3. RandomForest je takođe optimizovan prema dubini stabla i broju estimatora. Za osnovni skup podataka, Optimalna dubina stabla je 7, a broj estimatora 100. Stacking, ansambl tehnika mašinskog učenja kombinuje predikcije odabranih modela. Za krajnji model je izabran XGBoost zato što je dao najbolje rezultate na validacionom skupu. Strategija koja je korišćena u rešenju za agregaciju je strategija “mekog glasanja” (engl. *soft voting*). Implementiran je i model koji koristi LSTM neuronsku arhitekturu. Ova arhitektura je dizajnirana za obradu i modeliranje vremenskih serija i sekvencijalnih podataka. U našem slučaju, ulazni sloj sadrži jedan LSTM sloj sa 140 neurona, nakon čega sledi pet dodatnih LSTM slojeva, svaki sa 32 neurona. Za aktivacionu funkciju u svim LSTM slojevima korišćena je ReLU (*Rectified Linear*

Unit) funkcija. Nakon LSTM slojeva, sledi potpuno povezan sloj neurona sa *softmax* aktivacionom funkcijom na izlazu. U procesu obučavanja ovog modela, korišćen je Adam (*Adaptive Moment Estimation*) optimizator. Za merenje gubitka modela koristili smo kategoričku unakrsnu entropiju (engl. *categorical crossentropy*). Eksperimentalno smo utvrdile da sekvence dužine 3 pokazuju najbolje rezultate u našem slučaju. Pokušale smo da poboljšamo performanse modela eksperimentišući sa različitim hiperparametrima neuronske mreže, ali nismo postigli značajno bolje rezultate od arhitekture koja je opisana. Jedan od ograničavajućih faktora u našem slučaju je veličina skupa podataka. Imamo samo 936 instanci, što može biti nedovoljno za potpuno obučavanje ovako složenog modela. Smatramo da bi dobili bolje rezultate sa većim skupom podataka koji bi nam omogućili da bolje iskoristimo kompleksnost arhitekture koju smo definisali.

V. REZULTATI I DISKUSIJA

Prikaz rezultata će biti podeljen u dve celine. Prva celina se odnosi na postignute rezultate pri detekciji vozila, drugi deo se odnosi na postignute rezultate pri predikciji saobraćajnih gužvi.

Korišćeni modeli su testirani na posebno odvojenom testnom podskupu, koji nije bio korišćen u fazi obučavanja i optimizacije. Izbor mera evaluacije: preciznosti, osetljivosti i f1 mere, je usklađen sa prethodnim istraživanjima. Evaluacija je izvršena nad modelima koji su koristili empirijski dobijene najbolje parametre u koraku optimizacije modela nad validacionim skupom.

A. Rezultati detekcije vozila

Rezultati evaluacije detekcije vozila nad test skupom prikazani su u Tabela 1.

Tabela I Rezultati test skupa za YOLO model

Modeli	Mere performanse		
	Preciznost	Osetljivost	F1 Mera
Automobil	0.87	0.89	0.88
Autobus	0.84	0.83	0.83
Kamion	0.25	0.50	0.33
Ukupno	0.67	0.74	0.70

Tabela 1. Prikaz rezultata detekcije za test skup

Tabela II Rezultati test skupa za SSD model

Modeli	Mere performanse		
	Preciznost	Osetljivost	F1 Mera
Automobil	0.92	0.84	0.88
Autobus	0.52	0.46	0.49
Kamion	0.16	0.20	0.18
Ukupno	0.40	0.38	0.39

Tabela 2. Prikaz rezultata detekcije SSD za test skup

Rezultati evaluacije za kamion se znatno razlikuju u odnosu na automobil i autobus, što ima direktni uticaj na rezultate za sva tri vozila. Posledica malog broja entita kamiona na prikupljenim materijalima je loš rezultat detekcije kamiona. Kako je izabrana specifična ulica glavnog grada Srbije, prisustvo takve vrste vozila nije učestalo, u našem test skupu je bilo svega 2 instance kamiona. Takođe, nema raspodele na kombije i kamione, iz tog razloga smo kombije anotirali kao kamione, pri udaljenosti na kojoj se nalazi kamera izuzetno je teško raspoznati automobile od kombija. SSD model ima bolje performanse u odnosu na YOLO model za klasu koja u skupu podataka ima dosta instanci, dok je

pokazao lošije performanse za klase koje u skupu podataka imaju manje instanci. Pošto se YOLO model prilikom evaluacije po performansama pokazao bolji u odnosu na SSD model, u daljem radi i eksperimentima za detekciju vozila biće korišten YOLO model.

B. Rezultati predikcije saobraćajnih gužvi

Rezultati evaluacije predikcije saobraćajnih gužvi su prikazani u Tabela 3.

TABELA III REZULTATI TEST SKUPA

Modeli	Mere performanse		
	Preciznost	Osetljivost	F1 Mera
XGBoost	0.97	0.95	0.96
Random Forest	0.92	0.92	0.92
KNN	0.90	0.92	0.88
SVM	0.87	0.85	0.86
Stacking	0.93	0.93	0.93
LSTM	0.47	1.0	0.64

Tabela 3. Prikaz rezultata predikcije modela za test skup

Rezultati koje smo dobili su u pretežnoj korelaciji sa rezultatima prethodnih rešenja, što bi značilo da smo jednako uspešno izvršili predikciju saobraćajnih gužvi obradom video materijala sa nadzorne kamere. XGBoost se pokazao kao model sa najboljim performansama ostvarivši f1 meru od 96%, što ukazuje na visok kvalitet balansa između preciznosti i osetljivosti.

Posledica malog skupa podataka su loše performanse LSTM modela, napomenule bismo da je i pored tog malog broja podataka, LSTM ostvario osetljivost od 100%, preciznost je ta koja je veoma loša i koja traži još podataka. Nadalje, problem nekontinuiranih podataka dodatno je otežao upotrebu LSTM modela. U prethodnim istraživanjima ovaj problem je rešen usrednjavanjem podataka, međutim, to nije bilo izvodljivo u našem slučaju zbog prisustva podataka iz 2019. i 2020. godine, perioda koji su bili značajno uticajni na promene svih trendova, posebno saobraćajnih, zbog pandemije COVID-19, karantina i policijskog časa.


Nedostatak obimnog skupa podataka nije samo rezultat zahtevnog procesa prikupljanja i obrade podataka, već i tehničkih izazova koji su se pojavili i na koje nismo mogle da utičemo. Vremenski uslovi koji su onemogućavali obradu materijala, prikazani su na Fotografiji 6., gde su pahuljice snega ometale preglednost, naravno, isti problem se može javiti i pri padanju kiše.



Fotografija 6. Prikaz problema preglednosti kamere prouzrokovan vremenskim nepogodama

Jak vetar koji bi vidno pomerao kameru ili loša brzina prenosa podataka, doveli su do pogrešne procene brzine vozila u odnosu na druge materijale, zbog čega smo bile primorane da takav video materijal izuzmemo iz dalje obrade.

Još jedan problem vremenskih uslova je velika vlažnost vazduha, zbog koje se javlja jaka refleksija svetla koja rezultuje teško uočljivim vozilima zbog intenzivnog bljeska. Ova pojava se ponekad dešavala i tokom noći. Na Fotografiji 7. je jedan primer takve situacije, gde vozila u levoj traci ne možemo da detektujemo zbog jake refleksije.




Fotografija 7. Prikaz problema detekcije vozila usled velike refleksije svetla

Osim vremenskih uslova, problem je i sama kamera koja menja kadrove i na taj način utiče na broj detektovanih vozila. Menjanjem kadra, rešenje nije u mogućnosti da prati vozila detektovana u prethodnom kadru, već ih ponovo detektuje i na taj način uvećava broj vozila.

Na sve prethodne probleme rešenje je postavljanje kamere određenih specifikacija, posebnim načinom ugradnje, na posebnom mestu, ali postoji jedan problem koji je mnogo teže rešiti. Vozila koja su parkirana na parking mestima ili sa strane puta, ne prave gužvu na putu i ne utiču na saobraćaj, autobusi koji čekaju putnike na stanici, pasivno utiču na saobraćaj i ne utiču na gužvu na samom putu, bar ne dok čekaju putnike. Iako oni ne utiču na gužvu, rešenje ih detektuje, prati i primećuje da se ne kreću, pri čemu, kao i ostala vozila, aktivno utiču na podatke u rešenju.

U slučaju da kadar u određenoj meri pokriva parking mesta koja su većinski popunjena, rešenje bi taj slučaj potencijalno detektovalo kao gužvu. Jedan takav primer je na Fotografiji 7. gde samo dvoje vozila učestvuju u aktivnom, veoma prohodnom, saobraćaju, dok je devet parkirano, a naše rešenje pretpostavlja da većina vozila stoji, čeka i da je gužva.



Fotografija 8. Prikaz problema detektovanja parkiranih vozila

Problem ove prirode bi potencijalno mogao da se reši obučavanjem novog modela za detekciju parking mesta ili autobuskih stajališta, ali opet bi postojali slučajevi kada bi vozilo stalo u krajnjim trakama na putu, ne remetiivši protok saobraćaja na taj način, bez rešenja da se razlikuje takav vid stajanja u odnosu na čekanje i gužvu na samom putu.

VI. ZAKLJUČAK

U ovom istraživanju smo se bavili problemom predikcije saobraćajnih gužvi koristeći video materijale nadzornih kamera. Širom sveta je sve veći problem opterećenja saobraćajnih infrastruktura, što dovodi do ekonomskih gubitaka, bezbednosnih problema i ekoloških posledica. Naš cilj je bio razviti pristup koji bi omogućio efikasnu predikciju saobraćajnih gužvi, pružajući osnovu za unapređenje upravljanja saobraćajnom mrežom i smanjenje gužvi i njihovih negativnih posledica.

Kreirali smo skup podataka obradom video materijala nadzorne kamere koji je poslužio kao osnova za obuku više modela mašinskog učenja, kao što su XGBoost, Random Forest, KNN, SVM i LSTM. XGBoost se istakao kao najefikasniji model, postigavši f1 meru od 96%.

Prednost našeg rešenja leži u načinu prikupljanja podataka na osnovu nadzornih kamera. Naravno, postoje određena ograničenja specifikacija kamere i njene pozicije, koja treba ispoštovati kako bi se izbegli probleme sa vremenskim uslovima i delimično sa refleksijom svetla. U ovom istraživanju nismo mogli da utičemo na ovaj detalj ali smo identifikovali probleme i naveli njihova rešenja. Pored problema tehničke prirode, priložili smo i greške na koje je teže uticati poput parkiranih vozila koja daju lažan uvid u prisustvo gužve.

Za buduće istraživanje predlažemo proširenje skupa podataka podacima o socijalnim dešavanjima u blizini, radovima na putu u okolini, kao i dodatnu evaluaciju modela u različitim vremenskim uslovima i geografskim područjima. Takođe, poželjno bi bilo ponovo evaluirati modele nad većim skupom podataka i istražiti nove.

LITERATURA

- [1] TomTom Traffic Index – Live traffic statistics and historical data. (n.d.). TomTom Traffic Index – Live Traffic Statistics and Historical Data. <https://www.tomtom.com/traffic-index/>
- [2] World Health Organization, 2015. *Global status report on road safety 2015*. World Health Organization.
- [3] Ritchie, H., & Roser, M. (2024, March 18). *Cars, planes, trains: where do CO2 emissions from transport come from?* Our World in Data. <https://ourworldindata.org/co2-emissions-from-transport#article-citation>
- [4] *World's most polluted countries in 2023 - PM2.5 ranking / IQAIR*. (n.d.). <https://www.iqair.com/us/world-most-polluted-countries>
- [5] Zafar, N., & Ul Haq, I. (2020). Traffic congestion prediction based on Estimated Time of Arrival. *PloS one*, 15(12), e0238200.
- [6] Bokaba, T., Doorsamy, W., & Paul, B. S. (2022). A comparative study of ensemble models for predicting road traffic congestion. *Applied Sciences*, 12(3), 1337.
- [7] Shin, D. H., Chung, K., & Park, R. C. (2020). Prediction of traffic congestion based on LSTM through correction of missing temporal and spatial data. *IEEE Access*, 8, 150784-150796.
- [8] *Surčin, Serbia Weather History / Weather Underground*. (n.d.). <https://www.wunderground.com/history/daily/rs/sur%C4%8Din/LYBE/date/> (Accessed: March 20, 2024).
- [9] BeogradCom. (n.d.). YouTube. Retrieved from <https://www.youtube.com/@BeogradCom> (Accessed: March 20, 2024).
- [10] Zuraimi, M. A. B., & Zaman, F. H. K. (2021, April). Vehicle detection and tracking using YOLO and DeepSORT. In *2021 IEEE 11th IEEE Symposium on Computer Applications & Industrial Electronics (ISCAIE)* (pp. 23-29). IEEE.
- [11] Bull, A. (2003). Traffic Congestion: The Problem and how to Deal with it. (*No Title*).
- [12] Roboflow. (n.d.). Roboflow. Retrieved from <https://app.roboflow.com/>
- [13] Loshchilov, I., & Hutter, F. (2018). Fixing weight decay regularization in adam.
- [14] Amari, S. I. (1993). Backpropagation and stochastic gradient descent method. *Neurocomputing*, 5(4-5), 185-196.
- [15] Liu, Wei, et al. "Ssd: Single shot multibox detector." *Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14*. Springer International Publishing, 2016.
- [16] PASZKE, Adam, et al. Pytorch: An imperative style, high-performance deep learning library. *Advances in neural information processing systems*, 2019, 32.
- [17] LIN, Tsung-Yi, et al. Microsoft coco: Common objects in context. In: *Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part V 13*. Springer International Publishing, 2014. p. 740-755.
- [18] THECKEDATH, Dhananjay; SEDAMKAR, R. R. Detecting affect states using VGG16, ResNet50 and SE-ResNet50 networks. *SN Computer Science*, 2020, 1.2: 79.